

SDXL、Wan2.1、Wan2.2、HunyuanVideo 與 MiniMax H3：架構、訓練、Diffusion、推理及生態系深度比較

執行摘要

截至 2026 年 8 月 15 日，這五個模型其實代表了三個不同世代的生成模型設計哲學：**SDXL** 是成熟的高解像度 2D latent U-Net diffusion；**Wan2.1**、**Wan2.2** 與 **HunyuanVideo** 則代表大型影片生成從 U-Net 轉向 **Diffusion Transformer (DiT) + Flow Matching + 3D VAE** 的主流；**MiniMax H3** 再進一步，把文字、圖片、影片、音訊及編輯/參考任務放進同一個 omni-modal generation system，而不再將 T2V、I2V、video editing、audio generation 視為獨立模型。¹

最重要的結論有五點。

第一，SDXL 仍然是五者之中最成熟、最容易控制及最完整的擴充平台，但它不是影片模型。 SDXL 1.0 的核心 U-Net 約 **2.6B**，兩個固定文字 encoder 合計約 **817M**；它把 Transformer 計算集中到較低空間解像度層，並引入 original-size、crop、target-size 及多 aspect-ratio conditioning。以 LoRA、DreamBooth、Textual Inversion、ControlNet、IP-Adapter、inpainting 等而言，SDXL 的插件成熟度仍明顯高於本文四個影片家族。²

第二，Wan2.1 是目前最具「教科書價值」的開放大型影片模型之一。 阿里團隊披露了相當完整的架構及訓練資料：14B 模型是 40-layer、hidden size 5120、40-head、FFN 13824 的 DiT；1.3B 則是 30-layer、1536 hidden、12-head、FFN 8960。Wan-VAE 只有 **127M**，把影片壓縮為時間 $\times 4$ 、空間 $\times 8 \times 8$ 、16-channel latent；DiT 使用 full spatio-temporal attention、每層 text cross-attention、umT5 conditioning，訓練目標則是 logit-normal time sampling 下的 **Rectified-Flow/Flow-Matching velocity MSE**。³

第三，Wan2.2 最大突破並不是「參數更多」，而是把 diffusion timestep 本身變成 MoE routing variable。 A14B 由高噪聲及低噪聲兩個約 14B expert 組成，總容量約 **27B**，但每一步只啟用約 **14B**；高 noise expert 負責早期 global layout，低 noise expert 負責後期細節，切換點由 SNR 決定。這與 LLM 的 token-level sparse MoE 很不同，是一種 **timestep-level expert routing**。另外 TI2V-5B 使用新的 $4 \times 16 \times 16$ Wan2.2-VAE，再加 patchification 後等效達 $4 \times 32 \times 32$ token compression，因此可以在 24GB RTX 4090 上跑 720p。⁴

第四，HunyuanVideo 13B 最重要的技術特色是 MM-DiT 式的 dual-stream $\rightarrow$ single-stream fusion。 它共有 **20 個 dual-stream blocks + 40 個 single-stream blocks**，hidden size 3072、FFN 12288、24 heads $\times 128$ dimensions，並使用 3D RoPE。文字端不是單純 T5，而是 decoder-only MLLM 加 bidirectional token refiner，再加入 CLIP-Large global embedding。其 3D causal VAE 同樣採 $4 \times 8 \times 8$ 壓縮、16 latent channels；foundation model 用 Flow Matching、logit-normal timestep、velocity MSE 訓練，推理則直接用一階 Euler ODE solver。⁵

第五，也是對問題前提最重要的修正：公開資料並不支持「MiniMax H3 已 shelved」。 截至 2026 年 8 月 15 日，H3 明確沒有被擱置。MiniMax 在 2026 年 7 月 31 日正式推出 H3，Reuters 同日報道其發佈；其後 MiniMax 已公開 H3-Base 權重、GitHub repository、Hugging Face 格式，以及 SGLang/vLLM 本地部署方式。官方目前仍提供 H3 API，並以 Hailuo AI 提供服務。⁶

比較容易造成「H3 被 shelved」誤會的是：MiniMax 官方確實表示，**H3 設計期間「放棄了 Hailuo-02 的架構」**，原因是該架構雖有效率優勢，卻會增加 task generalisation 的複雜性；這是 **放棄前代 Hailuo-02 architecture，不是放棄 H3 項目**。另外，H3-Context-IR 與 H3-Regenerate-2K 的完整權重目前尚未開源，只由官方 API 提供，但這同樣不是 shelving。⁷

因此，如「shelved」是指 MiniMax 內部曾經取消某個未公開 H3 計劃版本，現有公開資料無法驗證；如是指目前的 **MiniMax H3 模型本身已取消或停止開發**，則與截至 2026-08-15 的公開事實相反。⁸

比較框架與關鍵屬性

先釐清一個容易混淆的術語問題：**DDPM、DDIM、latent diffusion、CFG 並不是互斥類別**。DDPM 通常描述訓練/前向加噪框架；DDIM、Euler、DPM++、UniPC 等主要是 inference solver；latent diffusion 表示 diffusion/flow 在 VAE latent 而非 pixel space 工作；Classifier-Free Guidance (CFG) 則是一種 conditional guidance 方法。Wan/Hunyuan 使用 Flow Matching 時，生成過程更自然地表述為學習 continuous velocity field，再用 ODE solver 積分，而不是傳統 DDPM reverse Markov chain。⁹

屬性	SDXL 1.0	Wan2.1	Wan2.2	HunyuanVideo	MiniMax H3
主要模態	圖片	影片/圖片	影片/圖片/語音變體	影片	統一文字、圖片、影片、音訊 → audio-video
生成 backbone	latent U-Net + Spatial Transformer	DiT	timestep-routed MoE DiT / 5B dense DiT	dual-stream → single-stream MM-DiT	33B dense single-stream Omni Transformer
核心參數	U-Net 2.6B	1.3B / 14B DiT	A14B：27B total、約14B active；另5B	約13B transformer	33B transformer
已披露主要輔助參數	text encoders 817M；VAE 約84M	Wan-VAE 127M；umT5 數量未由 Wan report 明列	VAE exact params 未披露	VAE、MLLM、CLIP exact counts 未披露	Qwen3-VL-32B H3-Encoder；33B 中約13B 為可 cache 的 AdaLN-related branches；兩個 VAE exact counts 未披露
Transformer 深度	U-Net 內 transformer depths 論文列 [0,2,10]	1.3B 30 layers；14B 40 layers	A14B 詳細新 technical report 未公開；官方 Diffusers config 顯示 40 heads	20 dual + 40 single = 60 blocks	層數尚未在公開 top-level technical material 明列

屬性	SDXL 1.0	Wan2.1	Wan2.2	HunyuanVideo	MiniMax H3
Attention	U-Net spatial self/cross-attn；雙 CLIP conditioning	full spatio-temporal self-attn + 每 block text cross-attn	Wan-family attention + timestep expert switching	dual-flow attention、single-stream multimodal attention、3D RoPE	unified multimodal full/sparse attention、3D MM-RoPE
Latent compression	約8×8 spatial	4×8×8，C=16	Ti2V-5B VAE 4×16×16；patch 後 4×32×32	4×8×8，C=16	VisualVAE 4×16×16，24 channels；patch 後等效 4×32×32
Training generative objective	discrete-time latent diffusion；1000 steps	Flow Matching / Rectified Flow velocity MSE	Flow-Matching inference family；2.2 的完整 training objective 未重新公開	Flow Matching velocity MSE	未公開 ；只明確知道 release checkpoint 已做 CFG distillation
timestep/noise	1000-step discrete schedule	$t \sim \text{logit-normal}$ ；noise↔data linear path	flow scheduler；MoE switch 依 SNR	$t \sim \text{logit-normal}$ ；linear path	未公開
CFG	是	是	是	embedded CFG / CFG-distilled variant	released checkpoints 已 CFG-distilled
代表 sampler	論文評測 50-step DDIM；Diffusers 可 Euler/DPM++ 等	UniPC flow scheduler；T2V 50、I2V 40 steps	UniPC 或 DPM++；flow shift	Euler ODE；官方常用 50 steps	sampling algorithm / step count 尚未完整公開
官方訓練時間	未披露	未披露	未披露	未披露	未披露
官方推理例	無跨硬件標準 latency	1.3B：RTX4090 5s 480p 約4分鐘	Ti2V-5B：4090、5s 720p <9分鐘	720p、129f、50 steps 約需 60GB；I2V 有多 GPU latency benchmark	官方建議 H3-Base 用4 GPU Ulysses；未公開標準 latency
LoRA	非常成熟	多個社群 trainer / Diffusers	DiffSynth 等支援 LoRA/full training	I2V 官方 LoRA scripts	官方 repo 暫未提供 LoRA training recipe

屬性	SDXL 1.0	Wan2.1	Wan2.2	HunyuanVideo	MiniMax H3
ControlNet 類控制	成熟	VACE/ adapter/ community 生態	ComfyUI/ DiffSynth/ community	I2V/token replacement/ custom variants	以 unified reference/edit conditioning 取代傳統 ControlNet 思 路；官方沒有 H3 ControlNet
Textual Inversion	支援	非主流／官 方未主推	非主流	官方未主推	官方未提供
本地部署成熟 度	很高	高	高	高，但硬件重	初期；Base 已 開，完整 2K pipeline 部分 仍靠 API

SDXL 數據來自 SDXL technical paper、官方 SGM config 及 Diffusers；Wan2.1 的 architecture/training detail 來自 Alibaba 的 60 頁 Wan technical report；Wan2.2 的 MoE、5B/VAE、推理要求來自官方 repository；HunyuanVideo 結構與 Flow Matching 來自 Tencent technical report；H3 則以 2026 年 7–8 月 MiniMax 官方 blog/repository 為準。¹⁰

架構、參數與訓練方法

SDXL 1.0。SDXL 仍是 latent diffusion U-Net，而不是 DiT。Base U-Net 約 **2.6B parameters**，model channels 以 320 為基礎，channel multipliers 為 `[1, 2, 4]`，即主要 feature widths 約 320/640/1280；每 level 有 residual blocks。相較早期 Stable Diffusion，SDXL 刪除了最深的 $8\times$ downsampling level，並把 Transformer 計算向較低解像度 feature maps 集中；論文 Table 1 將 transformer-block depth 列為 `[0, 2, 10]`。這是一個重要設計：高 spatial resolution 層避開昂貴 attention，而較低 resolution 層使用更深 attention。¹¹

文字 conditioning 使用 **CLIP ViT-L + OpenCLIP ViT-bigG**，兩者合計約 **817M parameters**；兩個 encoder 的 token embeddings concatenate 後形成 **2048-dimensional cross-attention context**，同時再使用 OpenCLIP bigG 的 pooled embedding 作額外 conditioning。換言之，SDXL 的 prompt understanding 不單靠「更大 U-Net」，而是 dual-encoder conditioning。¹²

VAE 沿用原 Stable Diffusion VAE 的基本 architecture，但由零重新訓練，batch size 從早期 SD VAE 的 9 大幅增至 **256**，並使用 EMA；公開 checkpoint 的 parameter count 約 **83.7M**。因此若把固定文字 encoder 及 VAE 也計入 resident model weights，SDXL Base 的已知 pipeline parameters 約 **3.50B**，但論文通常報的「2.6B」只是 U-Net。¹³

SDXL 的訓練 curriculum 披露得相當具體：先在 **256×256、global batch 2048 訓練 600,000 optimizer steps**；之後再以 512×512 約 **200,000 steps**；最後轉到接近 1024² pixel area 的多 aspect-ratio buckets，尺寸為 64 的倍數。它亦加入 original image size、crop coordinates 和 target size conditioning，以免直接丟棄低解像度圖片；論文指出若硬性排除低 resolution 圖片會丟失約 39% data。最後階段亦使用 offset noise，論文列出的 noise offset 為 0.05。¹⁴

SDXL 論文沒有完整披露 **base model 的 optimizer、learning-rate schedule、精確 dataset 規模/組成及整體 GPU-hours**；因此這些欄位不應以 Stable Diffusion 1.x/2.x 的設定直接填補。這是 SDXL 與 Wan2.1 technical report 透明度上的明顯差異。¹⁵

Wan2.1。Wan 的 architecture 可分為 **Wan-VAE → DiT → umT5 text encoder**。Wan-VAE 是 3D causal VAE，輸入 $(1+T) \times H \times W \times 3$ 會變成 $(1+T/4) \times H/8 \times W/8 \times 16$ ；第一 frame 特別只做 spatial compression，使同一套 VAE 可自然處理圖片。它把 GroupNorm 改成 RMSNorm，以維持 temporal causality 及支援 feature cache；另外縮減 decoder spatial-upsample channel，官方報告指出因此降低約 33% inference memory。整個 VAE 只有 **127M parameters**。 ¹⁶

DiT 的公開規格非常完整：

Wan2.1 backbone	Hidden dim	Latent in/out	FFN dim	Heads	Layers
1.3B	1536	16 / 16	8960	12	30
14B	5120	16 / 16	13824	40	40

每個 transformer block 做 full spatio-temporal modelling，並包含 **text cross-attention**；umT5 提供最多 512-token conditioning。timestep embedding 經 Linear + SiLU MLP 後產生六組 modulation parameters，MLP 在 blocks 間共享，但每 block 有獨立 bias。Alibaba 報告指出這個設計相較替代方案可減少約 25% parameters。 ¹⁷

Wan-VAE 自己有三階段訓練：先訓 2D image VAE；再 inflate 為 3D causal VAE，以低 resolution 128^2 、5-frame video 學習 temporal structure；最後在高質素不同 resolution/frame-length 影片 fine-tune。VAE loss 明確包括 **L1 reconstruction**、**KL**、**LPIPS**，權重分別為 **3**、 **3×10^{-6}** 、**3**；最後再加入 3D discriminator 的 GAN loss。 ¹⁶

14B DiT 則先做 **256px text-to-image pretraining**，然後進入 image-video joint curriculum：先 256px images + 192px、5 秒、16fps video；再升到 480px；最後 720px。官方披露使用 **BF16 mixed precision**、**AdamW**、**weight decay 1×10^{-3}** 、**initial LR 1×10^{-4}** ；learning rate 在 FID/CLIP Score plateau 時下調。 ¹⁸

其 generative loss 亦完全公開。對 data latent x_1 、Gaussian noise x_0 及 $t \sim \text{logit-normal}$ ：

$$x_t = tx_1 + (1 - t)x_0, \quad v_t = x_1 - x_0$$

模型以 MSE 學習 velocity：

$$\mathcal{L} = E \left[\|u_\theta(x_t, c, t) - v_t\|^2 \right].$$

因此 Wan2.1 嚴格而言不是傳統 epsilon-prediction DDPM，而是 **latent Rectified Flow / Flow Matching model**。 ¹⁹

資料方面，Alibaba 明確表示 pretraining corpus 達 **billions of images and videos**、約 **O(1) trillions of visual tokens**，但沒有披露精確 image/video 數字。原始候選資料來自內部有版權來源及 publicly accessible data；清洗包括 OCR/text coverage、aesthetic score、NSFW、watermark/logo、black border、overexposure、synthetic-image detection、blur、duration/resolution、visual-quality clustering 及 motion quality。第一輪篩選大約淘汰 **50%** 候選資料。它亦合成了「數億」含中英文文字的圖片以強化 visual-text rendering；post-training 再使用 millions 級高質素圖片及簡單/複雜 motion videos。 ²⁰

Wan2.2。A14B 最大轉變是 **兩個 diffusion timestep experts**。每個 expert 約 14B，總 parameter capacity 約 **27B**；early/high-noise expert 聚焦 global composition/layout，late/low-noise expert 聚焦 texture/detail。Expert switching 不是由 token router network 決定，而以 denoising timestep 的 **SNR threshold** 決

定，因此每一步只有約 14B active。這意味 Wan2.2 在不把每一步 FLOPs 翻倍的情況下，把不同 noise regime 的 capacity 分開。 ²¹

這裡需避免一個常見誤解：**A14B 不等於只有 14B weights on disk**。它是約 27B total capacity、14B active-per-step。這與 LLM MoE 的「總參數 vs active parameters」概念相似，但 routing dimension 是 diffusion noise stage，不是 individual token。 ²¹

另一路線 TI2V-5B 是 dense **5B** model，配新的 Wan2.2-VAE。VAE 本身達 $T \times H \times W = 4 \times 16 \times 16$ **compression**；再經 $1 \times 2 \times 2$ patchification，進入 Transformer 的有效 token reduction 為 $4 \times 32 \times 32$ 。這是 Wan2.2 能把 720p generation 壓至 consumer-GPU 級別的重要原因之一，而不是單純將 14B 縮成 5B。 ²¹

Wan2.2 公開資料量相對 Wan2.1 增加 **65.6% images**、**83.2% videos**，並加入 lighting、composition、contrast、colour tone 等 aesthetic labels。惟官方截至目前沒有發表像 Wan2.1 那份 60 頁 technical report 般完整的 2.2 training recipe，所以 **optimizer**、**LR schedule**、**完整 loss**、**確切 training steps**、**dataset absolute counts** 均應標為 **unspecified**；不能只因 repo 與 Wan2.1 同 lineage，就把所有 Wan2.1 optimizer hyperparameters 當成 2.2 已確認資料。 ²¹

HunyuanVideo。本文「Hunyuan」主要指 2024 年底開源的 **HunyuanVideo 13B foundation model**，而不是後來整個 HunyuanVideo 1.5/Avatar/Foley family。其核心 Transformer 採 **dual-stream-to-single-stream** architecture：先用 20 個 dual-stream blocks 分開處理 text/video representations，再以 40 個 single-stream blocks concatenate 並做 joint multimodal attention。Model width 為 **3072**、FFN **12288**、24 heads，每 head 128 dimensions，共 60 blocks；3D RoPE 把 positional dimensions 分配到 temporal、height、width。 ²²

這種架構比 Wan2.1 的「video self-attention + independent text cross-attention」更接近 FLUX/MM-DiT：較前層保留各 modality specialization，後層讓文字和 visual tokens 進入統一 self-attention space。Tencent technical report 亦明確表示沒有沿用常見的 2D spatial + 1D temporal attention factorisation，而是讓 blocks 處理完整 video-frame interactions。 ²³

Text conditioning 使用 pretrained decoder-only MLLM，再經 bidirectional token refiner；另外 CLIP-Large 的 pooled representation 提供 global guidance。這個 design 的優點是 prompt comprehension 更像大型 multimodal language model，但代價是 conditioning side 比純 CLIP/T5 更重。Tencent 沒有在 technical report 中完整列出這些輔助 modules 的 parameter totals，所以「**HunyuanVideo 13B**」主要是 **generation backbone** 規模，不應直接當作整套 **pipeline resident parameter count**。 ²⁴

其 causal 3D VAE 將時間壓縮 $\times 4$ 、空間 $\times 8 \times 8$ 、latent channel 16；VAE training 的 image:video mixture 為 **1:4**，loss 包括 **L1 reconstruction**、**KL**、**LPIPS perceptual** 及 **GAN adversarial loss**。 ²⁵

Foundation-model training 同樣採 Flow Matching：Gaussian noise 與 clean data latent 線性 interpolation、 t 由 logit-normal distribution 抽樣，以 velocity MSE 訓練。Curriculum 是先做 256/512-resolution image pretraining，再逐步 joint image-video training，最高擴展到約 960px。Dataset 只公開為 **internet-scale images and videos**，沒有 absolute count；optimizer、base learning rate、總 steps 亦未披露。Tencent 指其 progressive/scaling strategy 相較 naive scaling 可節省最多約 $5 \times$ compute，但這是相對 improvement，不代表已披露 absolute GPU-hours。 ²⁶

MiniMax H3。H3 的完整系統不是單一 checkpoint，而是：

H3-Context-IR $\rightarrow$ H3-Base $\rightarrow$ H3-Regenerate-2K。H3-Context-IR 負責把文字、圖片、影片、音訊及它們之間的關係轉成高度詳細的 contextual omni representation；H3-Base 做 768p 等級 audio-video

latent generation；Regenerate-2K 則讓同一基模利用原始 context 重新生成高解像度結果，而不是普通 pixel super-resolution。Context-IR 與 Regenerate-2K 截至本文日期仍主要由官方 API 提供，而 **H3-Base 已公開 weights**。 7

H3-Base 的文字/語意 encoder 使用 **完整 pretrained Qwen3-VL-32B**，取其第 50 層 hidden state 作 H3-Encoder representation。VisualVAE 是 causal architecture，公開設定為 **f16t4d24**：spatial compression $\times 16$ 、temporal $\times 4$ 、latent channels 24；進 Transformer 前再做 $1 \times 2 \times 2$ patching，所以 effective visual token compression 達 **temporal $\times 4$ 、spatial $\times 32 \times 32$** 。AudioVAE 處理 32kHz native stereo，左右聲道共享 encoder/decoder weights，但獨立 encode/decode；latent rate 約 40Hz/channel。 27

H3-Omni Transformer 本身約 **33B parameters, dense single-stream**。其中約 **13B** 位於 AdaLN-related modulation branches；MiniMax 表示這部分 conditioning-dependent output 可預先計算/cache，因此 inference-only 時不必一直把該 13B branch 當作 active transformer weights 留在 accelerator memory，實際主要 generation-core residency 約相當於 **20B**，另加 H3-Encoder 及 VAEs。若單純計算「已公開知道存在的完整 pipeline parameters」，33B transformer + 32B H3-Encoder 已經約 **65B**，而且尚未計 VisualVAE/AudioVAE；因此 33B 與 65B 代表的是不同 parameter-count 定義。 27

Transformer 將各 modality packed 成一條 unified multimodal sequence，以 3D multimodal RoPE 建立 position；attention/FFN 主體沒有為 video/audio 設獨立 expert，modality-specific design 主要出現在 I/O projection 和 AdaLN。MiniMax 亦表示 H3 在 training/inference 原生支援 sparse attention，不過首版 open-source runtime 以 full-attention implementation 為主，稀疏版本仍在逐步公開。 28

H3 的訓練透明度目前遠低於 Wan2.1。已知它在 pretraining 便混合 T2I、T2V、native stereo audio-video、multi-shot、T2A，以及 image/video/audio 的 generalized reference/editing，而且 reference/edit relationships 以自然語言描述；MiniMax 強調盡早 mixing modalities/tasks，而非先訓專用 model 再 merge。Context caption pipeline 對部分素材要消耗約 **100K inference tokens**，最後產出平均約 **4K-token contextual representation**。另外高壓縮 H3-VAE 被官方描述為帶來約 **4 $\times$ sequence-length benefit**；針對 understanding/generation workload 差異設計的 heterogeneous training system 則提升接近 **30% end-to-end throughput**。 29

然而截至 2026-08-15，MiniMax 尚未公開 H3 的 **optimizer、learning rate、training steps、dataset absolute size、data percentages、完整 loss function、Flow Matching/DDPM parameterisation、noise schedule**。官方 blog 明言更完整的 H3 Tech Report 仍會後續發表。故任何聲稱「H3 用某個特定 AdamW LR、某種 sigma schedule、某個 training token count」的資料，目前都不應視作官方確認。 29

Diffusion 類型與推理管線

SDXL 的 pipeline 是最典型的 latent diffusion：

```
prompt → dual CLIP → latent noise → 2.6B U-Net denoising → VAE decode → image
```

Base model 在固定 pretrained VAE latent 中訓練，以 **1000-step discrete-time diffusion process** 為基礎；SDXL paper 的大量比較採 **50-step DDIM、CFG 8.0**，但這只是論文評測配置，不等於部署時必須用 DDIM。Diffusers 可以把 scheduler 換為 Euler、Euler ancestral、DPM++ 等，所以「SDXL 是 DDIM model」是不準確的；DDIM 是 sampler，不是 backbone 類別。 30

SDXL 另一特色是可選 **Base → Refiner** 二段 pipeline：base 先建立整體 composition，refiner 在較低 noise regime 改善 local texture/detail。實務上若 latency 比最高 fidelity 更重要，可以直接只跑 Base；若用 FP16，約 3.5B 已知 parameters 的純 weight-storage 理論下限約 **7 GB**，但實際 VRAM 還要加 activations、

attention workspace、scheduler buffers 等，因此不能把 7GB 當作運行需求。SDXL 本身的 paper 沒有提供足夠標準化、可跨 GPU 比較的 wall-clock benchmark。 ³¹

Wan2.1：

```
prompt → umT5 → noise video latent → 30/40-layer DiT flow integration → Wan-VAE decode
```

官方 Diffusers example 使用 `UniPCMultistepScheduler`，`prediction_type="flow_prediction"`、`use_flow_sigmas=True`、1000 scheduler timesteps；720p 典型 `flow_shift=5.0`，480p 為 3.0，CFG example 為 5.0。官方原生 implementation 的 T2V-14B 通常採 **50 sampling steps**，I2V-14B 為 **40 steps**。 ³²

Wan technical report 特別指出 sampling 時約 50 次 DiT forward 是 latency 大頭，因此加入兩類 cache：attention output 跨 adjacent steps cache，以及後期 conditional/unconditional output similarity 的 CFG cache；在 Wan 14B T2V 上，官方報告 diffusion caching 帶來約 **1.62× inference speedup**。FP8 GEMM 使 DiT 約再加速 1.13×，特製 8-bit FlashAttention 約 1.27×；這些數字不應簡單相乘為「最終 2.3×」而不做實際 benchmark，因為各項 optimization 的 bottleneck 會互相重疊。 ³³

官方最有用的 consumer benchmark 是 **Wan2.1-T2V-1.3B：RTX 4090、5 秒 480p、未使用 quantization 約 4 分鐘；VRAM 約 8.19GB**。1.3B 雖可嘗試 720p，但官方明言其 720p training 較少，因此 480p 更穩定。 ³⁴

在 training/inference scaling 上，Wan 的真正瓶頸是長 sequence full attention。Alibaba 報告指出 sequence 接近 1M tokens 時，attention 可佔 end-to-end training compute **最高約 95%**；14B model、microbatch 1 的 activation 若不 shard 可超過 8TB。因此官方採 FSDP parameter sharding + 2D Context Parallelism，其中外層 Ring Attention、內層 Ulysses。這說明為何「14B video DiT」的實際成本遠高於只看 parameter count 推算的 14B LLM。 ³⁵

Wan2.2 A14B 的 sampling 本質仍是 Wan flow-scheduler family；官方 `generate.py` 提供 **UniPC 或 DPM++** solver 並有 flow-matching `sample_shift`。最大差異是在 denoising trajectory 中間根據 SNR 把 active expert 從 high-noise 切到 low-noise，而不是每 step 同時跑兩個 14B networks。 ³⁶

部署效率最佳的則是 **Ti2V-5B**：官方表示在沒有專門 optimization 的情況下，單張 consumer GPU 可生成 5 秒 720p video，RTX 4090 command 要求至少 **24GB VRAM**，generation time **少於 9 分鐘**；80GB GPU 可移除 model offload、dtype conversion 及 T5-to-CPU 等措施以提高速度。 ⁴

HunyuanVideo：

```
prompt → MLLM/token refiner + CLIP → 3D latent noise → Flow-Matching MM-DiT → Euler ODE → causal VAE decode
```

Tencent 的 technical report 明確使用 first-order **Euler solver**；官方 repository 常見 inference configuration 是 **50 steps、129 frames、720×1280**。720p/129-frame inference 官方列出約 **60GB peak GPU memory**，544×960×129 則約 45GB；FP8 weights 可再減少約 10GB weight-related GPU memory。 ³⁷

HunyuanVideo-I2V 的官方 parallel benchmark 對 1280×720、129 frames、50 steps 報告 latency 約由 **1904.08 秒 (1-way) 降至 337.58 秒 (8-way)**，約 5.64× speed-up；由於該 benchmark 的硬件與完整

software stack 必須連同 repository context 才能公平解讀，不適宜直接拿 337 秒跟 Wan 的 RTX4090 數字作「哪個模型快幾倍」比較。³⁸

MiniMax H3 則要特別區分「完整產品 pipeline」與「開源 Base」：

```
multimodal inputs → Context-IR → H3-Encoder/VAEs → H3-Base joint audio-video generation → optional in-context Regenerate-2K
```

目前開源 checkpoint 分兩個 BF16 family：**FL2VA** 支援 text-to-audio-video 及 first/last-frame-to-audio-video；**Ref2VA** 接收文字加 reference images/videos/audio。兩者均是 **CFG-distilled Omni Transformer weights**。³⁹

MiniMax 官方本地 deployment example 使用 **4 GPUs + Ulysses degree 4** 的 SGLang server；完整 2K workflow 則需要把本地 H3-Base 與 MiniMax 的 H3-Context-IR / H3-Regenerate-2K API 串接。⁴⁰

但目前公開 material 沒有足夠資料嚴謹回答 H3「訓練到底是 DDPM、EDM、Rectified Flow 還是其他 continuous diffusion formulation」、「用多少 sampling steps」、「scheduler sigma/timestep schedule 是甚麼」。**CFG-distilled** 只證明 guidance 已經被 distill 到 release checkpoint，不能據此反推出原始 diffusion objective。這部分應標 **unspecified**，而不是猜測。⁴¹

擴充生態、變體與公開採用

在 extension ecosystem 上，五者的差距非常大。

SDXL 是明顯第一。Hugging Face Diffusers 原生支援 SDXL LoRA，LoRA 可以作用於 U-Net 及 text encoder；DreamBooth 與 LoRA 可組合；dual text encoders 亦支援 Textual Inversion。ControlNet-SDXL 可接受 depth、edge、pose、segmentation 等 spatial controls；IP-Adapter 則額外加入 image-conditioning cross-attention。這種「凍結 backbone + 小型 adapter」模式令 SDXL 成為研究 controllability、personalisation 及快速 domain adaptation 最低風險的平台。⁴²

SDXL 常見官方/主要 checkpoint lineage 包括 **SDXL 0.9**、**SDXL Base 1.0**、**SDXL Refiner 1.0**，以及後續以少步數 inference 為目標的 SDXL family 衍生模型；此外大量 fine-tuned SDXL checkpoints、ControlNets、IP-Adapters 形成了遠比影片模型成熟的社群市場。SDXL 亦曾透過 **Amazon Bedrock** 與 **SageMaker JumpStart** 提供；AWS 現行文件仍記錄 SDXL lineage，但 AWS 已把重點轉向 Stability AI 後來的 Stable Image/SD3.5 系列，舊 Stability models 正進入 deprecation 路線。⁴³

因此可公開核實的公司/平台採用包括 **Stability AI 本身**、**Amazon AWS/Bedrock/SageMaker**；AWS 亦曾以 SDXL 做 inpainting/outpainting creative workflow 示範。⁴⁴

Wan2.1 的官方 family 包括 T2V-1.3B、T2V-14B、I2V-14B-480P、I2V-14B-720P，並延伸至 first/last-frame、editing、personalisation、T2I、video-to-audio 等 research/application branches。它已被 **Hugging Face Diffusers** 及 **ComfyUI** 原生整合；官方 repository 同時收錄 TeaCache、CFG-Zero、UniAnimate-DiT 等 community extensions。⁴⁵

LoRA 方面，Wan 沒有 SDXL 那樣一個單一「標準插件市場」，但 DiffSynth-Studio、ComfyUI WanVideoWrapper 以及多套 trainer 已提供 LoRA/fine-tuning；長片、人物動畫、cache acceleration、FP8 等研究亦大量以 Wan2.1 作 foundation。這是 Wan2.1 的另一優勢：14B checkpoint 足夠強，同時 weights/code 全開，因此成為大量 video-generation research 的 de facto backbone。⁴⁶

公司/平台層面，**Alibaba/Alibaba Cloud** 不只開源模型，Model Studio/DashScope 亦持續提供 Wan2.1 及後續 Wan family API；**fal.ai** 亦公開提供 Wan2.1 T2V API。這些是可核實的「公開 integration/service」，比單純聲稱某企業內部 production 使用更可靠。 47

Wan2.2 已知主要 checkpoints 包括 **T2V-A14B**、**I2V-A14B**、**TI2V-5B**、**S2V-14B**，另有 Wan-Animate 等 specialised branches。ComfyUI 已有 native Wan2.2 workflow；DiffSynth-Studio 支援 low-memory layer-by-layer offload、FP8、sequence parallel、LoRA training 乃至 full training；Cache-DiT 類工具則可對 MoE model 做 cache acceleration。 48

值得留意一個相容性 caveat：Wan2.2 官方 repo 明確提醒 **Wan-Animate 不建議直接使用一般 Wan2.2 LoRA**，因為其 training weight changes 可能造成 unexpected behaviour。也就是說，「同屬 Wan2.2」不代表所有 downstream checkpoints 的 LoRA 空間完全 interchangeable。 21

Alibaba Cloud 現時的 legacy API 仍明確支援 **wan2.2/wan2.1**；例如 first/last-frame Wan2.2 及 S2V API 都有 production endpoint。故 Alibaba/Alibaba Cloud 是最明確可核實的商用提供方；ComfyUI、Hugging Face/Diffusers 則屬 framework integration，而不是企業 end-customer adoption 證據。 49

HunyuanVideo 的重要 checkpoint/branch 依時間包括原版 T2V 13B、**HunyuanVideo-I2V**、HunyuanCustom、HunyuanVideo-Avatar、Foley，以及後來的 **HunyuanVideo-1.5 8.3B** family。I2V 官方 repository 已直接提供 **LoRA training scripts**，並示範特效 LoRA；亦支援 xDiT Ulysses sequence-parallel inference、FP8、ComfyUI wrapper 等。 50

它不像 SDXL 般以 Textual Inversion/ControlNet 為主要 abstraction；I2V 用的是 **token replacement + MLLM image semantic tokens**，後續 Custom/Avatar 等亦更傾向在 foundation DiT 上加入 task-specific conditioning。因此對研究者而言，Hunyuan 的 extension 思路更接近「修改 multimodal condition path」而非「把一個 generic ControlNet 掛到 frozen U-Net」。 38

公司層面最明確的是 **Tencent** 自身；公開資料足以證明其開發、open-source 及產品化，但我沒有找到同等可靠的一手資料足以列出一批「已在 production 使用 open HunyuanVideo 13B weights 的外部大型企業」。因此不應把 Hugging Face/ComfyUI support 誤寫成企業 customer adoption。 51

MiniMax H3 的 open checkpoints 現時主要是：

Checkpoint	任務
H3 Base FL2VA	T2VA、first/last-frame → audio-video
H3 Base Ref2VA	text + image/video/audio references → audio-video

兩者均提供 original 及 Diffusers-style repository format，並已可由 SGLang 部署；官方 repository 同時提供 vLLM/SGLang integration 路線。 52


H3 目前沒有官方 LoRA trainer、ControlNet、Textual Inversion recipe 可與 SDXL 直接對等比較。它的設計方向反而是把 **reference**、**editing**、**audio conditioning** 原生吸收進 **base model**，理論上減少「每多一種任務就加一個 plugin」的需要。不過這也意味 fine-tuning 成本高得多：33B generation Transformer 加 32B encoder 的模型體積，遠高於 SDXL 或 Wan2.1-1.3B。 53

公開可驗證的 commercial deployment 首先是 **MiniMax/Hailuo AI 及 MiniMax API**。Reuters 報道 H3 針對 advertising、e-commerce、product design、gaming 等 commercial sectors，但截至 2026-08-15，沒有足

夠可靠公開資料讓我列出一批已確認把 H3 投入 production 的外部 named enterprise customers；因此這部分應寫「未公開披露」，而不是推測。 54

發佈時間線、參數分布與訓練計算估算

主要發佈順序顯示了一條很清楚的技術路線：2023 的 SDXL 仍是 enlarged latent U-Net；2024 HunyuanVideo 已轉至 13B MM-DiT/Flow Matching；2025 Wan2.1 把 open-video DiT architecture、VAE、training recipe 系統化，Wan2.2 再加入 timestep MoE；2026 H3 則走向 native omni-modal audio-video generation。 55



Wan2.1 的 GitHub release date 為 2025 年 2 月 25 日，technical report 初版在 3 月 26 日；Wan2.2 主版本在 2025 年 7 月推出；H3 則在 2026 年 7 月 31 日正式 launch，因此把 H3 描述成「已 shelved」尤其與目前時間線不吻合。 56

下面的參數圖只畫可以從公開資料合理核實的 **submodules**。空白不代表 parameter count 為零，而是「沒有足夠精確的公開數字」。Wan2.2 的 27B 是兩 expert 總容量，每 step active 約 14B；H3 則刻意把 33B Transformer 拆為約 20B main inference-resident core + 約 13B cacheable AdaLN-related branches，另外加入已明確指出的 32B H3-Encoder。SDXL VAE 約 84M 是公開 checkpoint parameter count，並非 SDXL paper 本身的 headline number。 57

公開可核實的參數構成；未披露項目未計入

[下載參數分布圖 PNG](#)

訓練時間與 compute 的估算方法

所有五個模型的實際完整 training wall-clock/GPU-hours 都沒有由作者完整公開；SDXL 有 optimizer-step stages，Wan2.1 有 token-scale/data/training recipe，Hunyuan 有 progressive strategy，但仍不足以重建實際 cluster utilisation；Wan2.2/H3 的缺口更大。所以下圖應理解為 **capacity-planning range**，而不是聲稱還原廠商真實成本。 58

我採用以下統一假設：

硬件：H100 SXM 80GB 等效；每 GPU 長時間 BF16 training 的 effective sustained throughput 假設 **300 TFLOP/s**，已把理論峰值與實際 MFU 差距納入。

Cluster：以 1024 GPUs 計算 wall-clock equivalent；實際公司可能使用 H800/H20/國產 accelerator/A100 等，因此這只是一把共同尺。

Video high-resolution microbatch：假設約 **1 clip/GPU**；image stages 約 1–4 samples/GPU；以 gradient accumulation / DP 把 effective global batch 推到數百至約 2,000 samples。這與 Wan 論文指出長 video sequence microbatch 受 memory 嚴重限制的觀察一致。 ³⁵

DiT FLOPs：用 $6N_{\text{active}}D$ 作 linear-transformer lower-order baseline，再乘 **1.5–4× long-sequence attention/architecture factor**；Wan 報告指出 attention 在極長 sequences 可佔 95% compute，因此不能直接沿用 LLM 的 $6ND$ 而不加修正。 ⁵⁹

SDXL：以已知 600k@256、200k@512 steps，global batch 2048（已公開部分）再加未披露 1024/multi-aspect stage，假設最後階段約 100k–300k-equivalent steps；由於 convolutional U-Net FLOPs 不適合直接套 DiT token formula，因此其 range 信心最低。 ⁶⁰

Wan2.1：假定 14B active backbone 處理約 **1–2T effective visual tokens**，與官方「O(1) trillions」一致；optimizer-step equivalent 粗略假設約 150k–600k。 ²⁰

Wan2.2：假定每 step 仍只有約 14B active，但 effective training data/token exposure 較 2.1 提高約 1.7× 上下；optimizer-step equivalent 約 200k–800k。官方只披露 image/video data 增幅，故這裡不假裝知道實際 resampling ratios。 ²¹

HunyuanVideo：因只有「internet-scale」而無 token count，假設約 0.5–2T effective latent tokens、約 200k–800k steps。 ²³

H3：假設 33B generation Transformer、1–4T effective multimodal target/context token exposure、約 300k–1M optimizer steps；因 H3-VAE 高壓縮及 sparse-attention design 可降低 sequence cost，attention multiplier 使用較闊的 1.5–3×。此項不包括重新預訓 Qwen3-VL-32B 本身，因 H3 官方稱它為 pretrained H3-Encoder。 ⁵³

由此得到的**非官方**估算為：

模型	官方 training time	本文 H100-equivalent GPU-hours 粗估	若用 1024×H100 等效 wall-clock	主要不確定性
SDXL	unspecified	約 0.03–0.20M	約 1.2–8.1 日	1024 stage steps、U-Net 實際 throughput
Wan2.1-14B	unspecified	約 0.19–0.75M	約 7.7–30.5 日	「O(1) trillions」實際 token count、video mix
Wan2.2-A14B	unspecified	約 0.32–1.30M	約 13–53 日	是否大量 warm-start、自 2.1 繼承多少訓練、expert schedule
HunyuanVideo	unspecified	約 0.09–0.70M	約 3.7–28.5 日	dataset/token count 完全未披露
MiniMax H3	unspecified	約 0.28–2.20M	約 11–90 日	data scale、sparse-attn 比例、task mixing、warm-start 程度

非官方 H100-equivalent training compute capacity-planning estimates

[下載訓練計算量估算圖 PNG](#)

這些範圍的用途是做**基礎設施設計與量級比較**，不是估計公司帳單。例如 Wan2.2 若 substantial warm-start from Wan2.1，其 incremental training compute 可以遠低於從零訓練同樣 data exposure；H3 若大量 reuse pretrained encoders/VAEs，亦同理。反過來，若 data curriculum 有多輪 epoch、re-captioning、rejection

sampling 或大規模 post-training，實際 end-to-end compute 又可以超出上述 generation-backbone estimate。Wan 的 caption model/data-preparation pipeline 本身就包含額外大規模 MLLM inference，而 H3 更明言部分素材的 Contextual Omni Representation construction 要消耗約100K inference tokens，所以「foundation-model training FLOPs」並不是完整 data-factory 成本。⁶¹

技術創新、瓶頸與部署／研究含義

從架構演進看，SDXL 的核心創新是「把昂貴的 representation capacity 放到正確 spatial scales」，而不是無限制增大所有 U-Net levels；dual text encoders、size/crop conditioning、多 aspect-ratio training 亦顯著改善 1024px generation。這種 architecture 仍非常適合圖片 production，因 2D latent sequence 很短，ControlNet/LoRA 插件可以用相對低成本訓練。它的主要瓶頸則是 U-Net architecture 不具現代 DiT 那種簡單 scaling law，而且 prompt/scene reasoning 明顯受限於 CLIP family text representation。⁶²

因此，圖片生成、品牌 style LoRA、精確 pose/depth/edge control、低成本 fine-tune：SDXL 仍是這五者最實際的工程選擇。若研究目標是新式 large-scale video/world model，SDXL 則已不是最有代表性的 backbone。⁶³

Wan2.1 的最大研究價值是完整性。 127M causal VAE、full spatio-temporal DiT、Flow Matching、公開 data curation、FSDP+2D context parallel、cache/FP8 optimization 被放在同一份 technical report 中，令它特別適合作為研究 video DiT scaling、sparse attention、distillation、long-video、controllability 的 baseline。⁶⁴

它最大的 bottleneck 也最明顯：**full spatio-temporal attention 的 $O(L^2)$** 。VAE 已把影片大幅壓縮，但 720p × 多十 frames 仍會產生非常長 latent sequence；Wan 自己的測量顯示 million-token regime attention 可佔95%時間。這使 sparse/windowed/block attention、context compression、KV/attention reuse、distillation 成為比「再把14B加到30B」更重要的研究方向。⁶⁵

Wan2.2 的 timestep MoE 是非常值得延伸的 idea。 Diffusion trajectory 本來就不是 stationary computation problem：高 noise 階段主要決定 global semantics/geometry，低 noise 階段主要恢復 texture/detail。把同一 dense model 強迫學兩種 regime 可能不是最有效 capacity allocation。Wan2.2 直接用兩個 experts 解耦，可視為 diffusion-specific conditional computation。下一步研究自然包括多於兩 experts、continuous expert interpolation、按 spatial frequency routing、按 modality routing，以及 expert-specific quantization/distillation。²¹

其瓶頸是 **27B total weights 仍然要存放、載入及管理**。即使每一步只 active 14B，磁碟、CPU RAM、PCIe/NVLink traffic、expert switching 都不是免費；「FLOPs 幾乎不變」不等於「整個 deployment cost 幾乎不變」。對 edge/consumer deployment，反而 TI2V-5B 的 high-compression VAE 路線可能比 A14B MoE 更重要。⁴

HunyuanVideo 的 dual→single stream 是 representation-fusion 的折衷。 完全 cross-attention 的 Wan pattern 容易保留 video/text role separation；完全 single-stream 則容易讓 modalities 深度 interaction，但成本高。Hunyuan 前20層先各自處理，再40層 joint fusion，可看成把 specialization 與 multimodal reasoning 分階段處理。配合 MLLM text encoder，它特別適合研究 complex prompt semantics、multimodal conditioning、I2V identity consistency。⁶⁶

部署瓶頸是 hardware footprint：官方 720p 129-frame configuration 約60GB peak VRAM，單張24GB consumer GPU 並不是原版 HunyuanVideo 的自然 deployment target。實務上要依靠 CPU offload、FP8、xDiT sequence parallel，或者改用後來較小的 HunyuanVideo-1.5 family。⁶⁷

H3 最重要的創新不是「33B」，而是把 task taxonomy 消掉。 在它的設計裡，「參考這段影片的 camera motion、用那張圖的人物、唱這段 audio 的音色」不需要先決定究竟屬於 Motion ControlNet、IP-Adapter、voice clone 還是 I2V；所有 context 先被語言化/統一 representation，再交給同一 Omni Transformer。MiniMax 把 language 稱為不同 modality/task 之間可 scaling 的 generalisation bridge。²⁹

這種設計的長期意義可能比單純 VBench 分數更大：生成模型的 API 可以從「選模型 → 選 control module → 調 strength」轉成「把所有素材和自然語言 intent 放進 context」。它與大型 language model 從 task-specific classifiers 走向 instruction-following foundation model 的歷史非常相似。這是基於 H3 架構方向所作的研究推論，而不是 MiniMax 已證明所有 specialised controls 都會被淘汰。²⁹

H3 當前最大的問題則有三個：**透明度不足、模型體積巨大、完整 pipeline 尚未完全開源**。33B generation model + 32B encoder 已知 weights 已達約65B；完整 2K 還要 Context-IR/Regenerate-2K；而 loss、optimizer、dataset scale、diffusion parameterisation、sampling schedule 仍未公開。因此現階段 H3 比較適合「研究 unified multimodal generation / high-end hosted deployment」，而不是要求完全可重現 training recipe 的 academic baseline。⁷

若從部署決策直接落地，可以概括為：

工作負載	最合理首選	原因
1024px 圖片、LoRA、ControlNet、brand style	SDXL	生態最成熟、插件最多、資源最低
Consumer GPU 影片研究	Wan2.1-1.3B	8.19GB級官方 footprint、training/inference stack 完整
高質素開源 T2V/I2V research	Wan2.1-14B	技術報告最完整、研究生態強
720p consumer deployment	Wan2.2-TI2V-5B	4×16×16 VAE、24GB 4090 可運行
高質素 timestep-MoE research	Wan2.2-A14B	diffusion-specific MoE 最具研究價值
MLLM-conditioned / identity-sensitive video	HunyuanVideo	dual→single MM-DiT、I2V/LoRA 官方路線
text+image+video+audio joint reference/edit	MiniMax H3	原生 omni-modal context + audio-video joint generation
完全 reproducible training research	Wan2.1 優於 H3	Wan 公開 loss、optimizer、data pipeline；H3 尚缺 Tech Report

上述 deployment judgement 是由各官方 architecture、VRAM、open-source scope 及 extension support 所作的工程推論。⁶⁸

主要來源、連結與註釋

SDXL

[SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis — arXiv](#) — SDXL 最核心的一手來源；包含 U-Net 2.6B、dual text encoders、size/crop conditioning、multi-aspect training、VAE 及 training stages。⁶⁹

[Stability AI generative-models — GitHub](#) — SDXL 官方 inference/config implementation，可核對 channel、attention、conditioning configuration。 70

[Hugging Face Diffusers — SDXL](#) — production pipeline、dual encoder、Textual Inversion 等。 71

[Diffusers — ControlNet SDXL](#) — SDXL ControlNet conditioning 及自訓支援。 72

[Diffusers — IP-Adapter](#) — image-prompt cross-attention adapter；包含 SDXL usage。 73

[AWS — Stability AI models in Amazon Bedrock](#) — 可核實 SDXL lineage 在 AWS 商用 managed-service 生態中的歷史採用及後續轉移。 74

Wan2.1

[Wan: Open and Advanced Large-Scale Video Generative Models — arXiv](#) — 本比較中資訊最完整的 video model technical report；架構、VAE、loss、optimizer、data cleaning、parallelism、quantization 均有詳細披露。 75

[Wan2.1 — Official GitHub](#) — checkpoints、generation scripts、Diffusers/ComfyUI integration、GPU efficiency 及 variants。 76

[Wan2.1 T2V-14B — Hugging Face](#) — 官方 model card；包含 1.3B consumer benchmark 及 checkpoint table。 34

[Alibaba Cloud Model Studio — Wan video generation](#) — Wan family 的 production API/product evidence。 77

[fal.ai — Wan2.1 API](#) — 第三方商用 hosted inference integration。 78

Wan2.2

[Wan2.2 — Official GitHub](#) — A14B MoE、27B/14B active、SNR expert switching、T2V-5B、Wan2.2-VAE、4090 benchmark 的主要一手來源。 21

[Alibaba Cloud — Wan text-to-video API](#) — 明確記錄 legacy interface 對 Wan2.2/Wan2.1 的服務支援。 79

[Alibaba Cloud — Wan2.2 S2V API](#) — Speech-to-Video production endpoint 及 480p/720p pricing/service configuration。 80

[ComfyUI — Wan2.2 workflow](#) — native ComfyUI integration。 81

HunyuanVideo

[HunyuanVideo: A Systematic Framework For Large Video Generative Models — arXiv](#) — 13B architecture、20+40 blocks、3D VAE、Flow Matching、data/training infrastructure 的主要一手 technical report。 23

[HunyuanVideo — Official GitHub](#) — inference configuration、VRAM、FP8、xDiT deployment。 67

[HunyuanVideo-I2V — Official GitHub](#) — token-replacement I2V、LoRA training、parallel inference benchmark。 38

MiniMax H3

[MiniMax H3 官方中文技術博客](#) — 2026-07-31 H3 正式 launch、training philosophy、Contextual Omni Representation、H3-VAE、放棄 Hailuo-02 architecture 的真正含義、+30% heterogeneous-training throughput 等重要一手來源。 29

[MiniMax-H3 — Official GitHub](#) — 已公開 H3-Base weights；33B Omni Transformer、32B H3-Encoder、Visual/Audio VAE、CFG-distilled checkpoints、FL2VA/Ref2VA、SGLang deployment 及完整2K API workflow。 52

[MiniMax H3 English official blog](#) — 官方英文 launch page；確認 H3 為 general-purpose multimodal generation model。 82

[Reuters — China's MiniMax releases H3 video model](#) — 獨立新聞來源，確認 2026 年 7 月 31 日 launch、15秒、2K、native stereo，以及 MiniMax 對 open weights/commercial deployment 的公開定位；亦再次證明截至目前不能把 H3 說成已 shelved。 83

1 2 10 11 12 13 14 15 30 31 55 58 60 62 69 SDXL: Improving Latent Diffusion Models for High-Resolution Image Synthesis

<https://arxiv.org/html/2307.01952>

3 17 32 76 GitHub - Wan-Video/Wan2.1: Wan: Open and Advanced Large-Scale Video Generative Models • GitHub

<https://github.com/Wan-Video/Wan2.1>

4 21 48 57 GitHub - Wan-Video/Wan2.2: Wan: Open and Advanced Large-Scale Video Generative Models • GitHub

<https://github.com/Wan-Video/Wan2.2>

5 22 23 24 25 26 37 51 66 HunyuanVideo: A Systematic Framework For Large Video Generative Models

<https://arxiv.org/html/2412.03603v1>

6 54 83 China's MiniMax releases H3 video model

https://www.reuters.com/world/china/chinas-minimax-releases-h3-video-model-2026-07-31/?utm_source=chatgpt.com

7 8 29 53 MiniMax H3：打破任务和模态的边界 - MiniMax Research | MiniMax

<https://www.minimaxi.com/blog/minimax-h3>

9 16 18 19 20 33 35 59 61 64 65 68 Wan: Open and Advanced Large-Scale Video Generative Models

<https://arxiv.org/html/2503.20314v2>

27 28 39 40 41 52 GitHub - MiniMax-AI/MiniMax-H3 • GitHub

<https://github.com/MiniMax-AI/MiniMax-H3>

34 Wan-AI/Wan2.1-T2V-14B

https://huggingface.co/Wan-AI/Wan2.1-T2V-14B?utm_source=chatgpt.com

- 36 **Wan2.2/generate.py at main • Wan-Video ...**
https://github.com/Wan-Video/Wan2.2/blob/main/generate.py?utm_source=chatgpt.com
- 38 50 **Tencent-Hunyuan/HunyuanVideo-l2v**
https://github.com/Tencent/HunyuanVideo-l2v?spm=a2c6h.13046898.publish-article.7.73326ffaDsBViw&utm_source=chatgpt.com
- 42 **Load adapters**
https://huggingface.co/docs/diffusers/v0.31.0/en/using-diffusers/loading_adapters?utm_source=chatgpt.com
- 43 **Stability AI models - Amazon Bedrock**
https://docs.aws.amazon.com/bedrock/latest/userguide/model-parameters-stability-diffusion.html?utm_source=chatgpt.com
- 44 **Generate images using Amazon Bedrock with stability ...**
https://aws.amazon.com/blogs/dotnet/generate-images-using-amazon-bedrock-with-stability-diffusion-model-in-net/?utm_source=chatgpt.com
- 45 46 56 **Wan-Video/Wan2.1**
https://github.com/Wan-Video/Wan2.1?utm_source=chatgpt.com
- 47 79 **Wan2.7 - Text-to-Video API Reference**
https://www.alibabacloud.com/help/en/model-studio/text-to-video-api-reference?utm_source=chatgpt.com
- 49 **Wan -image-to-video-first and last frames API reference(2.2)**
https://www.alibabacloud.com/help/en/model-studio/legacy-image-to-video-by-first-and-last-frame-api-reference?utm_source=chatgpt.com
- 63 72 **ControlNet with Stable Diffusion XL**
https://huggingface.co/docs/diffusers/api/pipelines/controlnet_sd-xl?utm_source=chatgpt.com
- 67 **Tencent-Hunyuan/HunyuanVideo at tasarim-ai**
https://github.com/Tencent/HunyuanVideo?ref=tasarim-ai&utm_source=chatgpt.com
- 70 **generative-models/configs/inference/sd_xl_base.yaml at main • Stability-AI/generative-models • GitHub**
https://github.com/Stability-AI/generative-models/blob/main/configs/inference/sd_xl_base.yaml
- 71 **Stable Diffusion XL**
https://huggingface.co/docs/diffusers/api/pipelines/stable_diffusion/stable_diffusion_xl?utm_source=chatgpt.com
- 73 **IP-Adapter**
https://huggingface.co/docs/diffusers/using-diffusers/ip_adapter?utm_source=chatgpt.com
- 74 **Stability AI - Models in Amazon Bedrock – AWS**
https://aws.amazon.com/bedrock/stability-ai/?utm_source=chatgpt.com
- 75 **[2503.20314] Wan: Open and Advanced Large-Scale Video Generative Models**
<https://arxiv.org/abs/2503.20314>
- 77 **Video generation**
https://www.alibabacloud.com/help/en/model-studio/use-video-generation?utm_source=chatgpt.com
- 78 **Wan-2.1 (Text to Video) API on fal**
https://fal.ai/models/fal-ai/wan-t2v?utm_source=chatgpt.com
- 80 **Alibaba Cloud Model Studio:wan2.2-s2v API reference**
https://www.alibabacloud.com/help/en/model-studio/wan-s2v-api?utm_source=chatgpt.com

81 **Wan2.2 Video Generation ComfyUI Official Native Workflow ...**
https://docs.comfy.org/tutorials/video/wan/wan2_2?utm_source=chatgpt.com

82 **MiniMax H3: An Open Model Breaking the Boundaries ...**
https://www.minimax.io/blog/minimax-h3?utm_source=chatgpt.com